Segmentasyon, Nesne Tespiti

& YOLO

Bilgisayarlı Görü · Derin Öğrenme · Gerçek Zamanlı Tespit

YOLOv10	160+ FPS	mAP>55%	4 Tür
En Güncel Sürüm	Gerçek Zamanlı Tespit	COCO Benchmark	Segmentasyon Türü

Bilgisayarlı Görü — Görev Hiyerarşisi

🏷️ **Classification**

Görüntü Sınıflandırma

Görüntünün tamamına tek etiket atar.

Çıktı: Sınıf adı + olasılık skoru

Model: ResNet, VGG, EfficientNet

Kısıt: Konum bilgisi yok

📦 **Object Detection**

Nesne Tespiti

Her nesne için bounding box + sınıf.

Çıktı: [x,y,w,h] + sınıf + güven

Model: YOLO, Faster R-CNN, SSD

Kısıt: Piksel düzeyinde değil

🎨 **Semantic Seg.**

Semantik Segmentasyon

Her piksele sınıf atar (tek nesne yok).

Çıktı: Piksel maskesi

Model: FCN, DeepLab, U-Net

Kısıt: Aynı sınıf birbirinden ayrılmaz

🎭 **Instance Seg.**

Instance Segmentasyon

Her nesne örneği ayrı maske alır.

Çıktı: Nesne maskesi + sınıf

Model: Mask R-CNN, YOLACT

Kısıt: Daha yüksek hesaplama

Nesne Tespiti Temelleri — IoU · Anchor · NMS

IoU — Intersection over Union

IoU = Alan(Kesişim) / Alan(Birleşim)

IoU ≥ 0.5 → Zayıf eşleşme
IoU ≥ 0.75 → İyi eşleşme
IoU = 1.0 → Mükemmel eşleşme

True Positive (TP) için eşik genellikle 0.5 kullanılır.

Anchor Box Kavramı

Ön tanımlı referans kutulardır (aspect ratio + ölçek).

Model, anchor'a göre offset tahmin eder:
tx, ty → merkez kaydı
tw, th → boyut ölçeği

YOLO'da anchor-free (v8+) yaklaşım tercih edilir.

Non-Maximum Suppression (NMS)

Çakışan kutulardan en yüksek güven skoruna sahip olanı tut, diğerlerini sil. IoU eşiği aşanlar bastırılır.

Confidence Score

P(nesne var) × P(sınıf | nesne). Bu değer eşik altında kalan tespitler görmezden gelinir.

mAP — mean Average Precision

Her sınıf için AP hesaplanır, ardından ortalaması alınır. mAP@0.5 ve mAP@0.5:0.95 yaygın metriklerdir.

İki Aşamalı Detektörler — R-CNN Ailesi

R-CNN (2014)

1. Selective Search ile 2000 bölge öner
2. Her bölgeyi CNN ile işle
3. SVM ile sınıflandır

Hız: ~47 sn / görüntü
Sorun: Her bölge ayrı CNN → çok yavaş

2014

Fast R-CNN (2015)

1. Görüntüyü tek CNN'den geçir
2. RoI Pooling ile bölge özelliklerini çek
3. FC katmanla sınıfla + regress

Hız: ~0.5 sn / görüntü
İyileştirme: Paylaşılan özellik haritası

2015

Faster R-CNN (2016)

1. CNN özellik haritası
2. Region Proposal Network (RPN)
3. RoI Pooling + sınıflandırma

Hız: ~0.2 sn / görüntü
Yenilik: RPN öğrenilmiş bölge önerisi

2016

Mask R-CNN (2017)

Faster R-CNN + FCN maskesi

Her RoI için piksel maskesi üretir
→ Instance Segmentation

Hız: ~5 FPS (GPU)
RoIAlign: Subpiksel hassasiyeti

2017

Tek Aşamalı Detektörler — SSD & YOLO Ailesi Girişi

SSD — Single Shot MultiBox Detector (2016)

Mimari:
- VGG16 / MobileNet backbone
- Çoklu ölçekte özellik haritaları
- Her hücrede birden fazla anchor

Özellikler:
- Tek geçiş (tek aşama)
- 59 FPS (300×300, GPU)
- Küçük nesnelerde zayıf

Eğitim:
- Hard negative mining
- Multi-scale feature extraction
- Smooth L1 konum kaybı

YOLO — You Only Look Once (2015)

Temel Fikir:
Görüntüyü S×S hücreye böl.
Her hücre B kutu + C sınıf tahmini yapar.

Çıktı Tensörü:
$S \times S \times (B \times 5 + C)$
YOLO v1: $7\times7\times(2\times5+20) = 7\times7\times30$

Avantajlar:
- Gerçek zamanlı (45 FPS v1)
- Bütünsel bağlam öğrenir
- Kolay dağıtım

Kısıtlar (v1):
- Küçük & örtüşen nesnelerde zayıf
- Hücre başı 1 nesne sınıfı sınırı

YOLO Evrimi — v1'den v10'a Tarihsel Yolculuk

YOLO v1 · 2015

45 FPS

Grid tabanlı, tek geçiş
tespiti. Redmon et al.

YOLO v2 · 2016

67 FPS

Anchor box, Batch Norm
Darknet-19 backbone

YOLO v3 · 2018

30 FPS

3 ölçek, skip bağlantı
Darknet-53, FPN benzeri

YOLO v4 · 2020

65 FPS

CSP, PANet, Mosaic aug.
CSPDarknet-53

YOLO v5 · 2020

140 FPS

Ultralytics, PyTorch
Auto-anchor, ONNX export

YOLO v8 · 2023

160 FPS

Anchor-free, C2f blok
Seg+Pose+Classify dahil

YOLO v9 · 2024

Yüksek

GELAN + PGI loss
Bilgi kaybına çözüm

YOLO v10 · 2024

SOTA

NMS-free çıkarım
Dual-head atama

YOLOv8 Mimarisi — Backbone · Neck · Head

Backbone — CSPDarknet + C2f

- Giriş: 640×640 × 3 RGB görüntü
- Konvolüsyon + BatchNorm + SiLU aktivasyonu
- C2f Blok: Cross-Stage Partial + gradient akışı
- SPPF: Spatial Pyramid Pooling Fast
- 5 aşamalı özellik çıkarımı: P1–P5
- Çıktı: P3(80×80), P4(40×40), P5(20×20)

→

Neck — PAN-FPN

- PANet + FPN hibrit yapı
- Yukarı örnekleme: derin öz. → ince öz.
- Yan bağlantılar (skip connection)
- Çok ölçekli özellik birleştirme
- Büyük, orta, küçük nesne desteği
- Çıktı: 3 ayrı özellik haritası

→

Head — Anchor-Free Decoupled

- Konum kafası: 4 parametre (x,y,w,h)
- Sınıf kafası: C sınıf olasılığı
- DFL Loss: Distribution Focal Loss
- TaskAligned Assigner atama
- NMS ile çakışan kutu eleme
- ONNX / TensorRT export desteği

Semantik Segmentasyon — FCN · DeepLab · U-Net

FCN — Fully Convolutional Net (2014)

İlk tam konvolüsyonel segmentasyon modeli.

Boyutlu özellik haritaları
Transpoz konvolüsyon ile upsampling
Skip bağlantı: hassas detaylar

FCN-32s → FCN-16s → FCN-8s
Stride oranı azaldıkça detay artar.

DeepLab v3+ (2018)

Atrous (dilated) konvolüsyon ile geniş alıcı alan (receptive field).

ASPP: Atrous Spatial Pyramid Pooling
Çoklu ölçek bağlamı tek geçişte

Backbone: Xception / MobileNet
Depthwise separable conv

CRF post-processing: keskin sınırlar

U-Net (2015) — Biyomedikal

Encoder-Decoder simetrik yapı.

Encoder: özellik çıkarımı (max-pool)
Decoder: boyut geri kazanımı (upconv)
Skip concat: ince detaylar

Az veriyle yüksek başarı
Biyomedikal görüntüye özel

U-Net++ / Attention U-Net türevleri

Instance & Panoptic Segmentasyon

Instance Segmentasyon

Mask R-CNN (2017)

Faster R-CNN + piksel maskesi dalı.
RoIAlign: alt-piksel hassasiyet.
3 çıktı kafası: Box + Class + Mask

YOLACT (2019)

Gerçek zamanlı instance segm.
Prototype mask + lineer kombinasyon.
30+ FPS @ 550×550

SOLOv2 (2020)

Konum bazlı örnek ayrımı.
Dynamic convolution.
Ankorsuz, NMSsiz çalışır.

Panoptic Segmentasyon

Semantik + Instance birlikte:

Stuff (sayılamaz): Gökyüzü, zemin, yol
→ Sınıf maskesi (semantik)

Things (sayılabilir): Araba, insan, bisiklet
→ Nesne maskesi (instance)

Metrik: PQ — Panoptic Quality
PQ = SQ × RQ
SQ: Segmentation, RQ: Recognition

Modeller:
- Panoptic-FPN
- Mask2Former
- OneFormer (tek modelde hepsi)

Güçlü nokta: Eksiksiz sahne anlayışı

Değerlendirme Metrikleri — mAP · F1 · FPS · FLOPs

Precision & Recall

Precision = TP / (TP + FP)
→ Yanlış alarm oranı

Recall = TP / (TP + FN)
→ Kaçırılan nesne oranı

F1 = 2 × (P × R) / (P + R)
Harmonik ortalama

Average Precision (AP)

Precision-Recall eğrisinin altındaki alan.

AP@0.50: IoU eşiği 0.50
AP@0.75: Daha sıkı
AP@.50:.95: COCO standardı

Her sınıf için ayrı hesaplanır.

mAP — mean AP

Tüm sınıfların AP ortalaması.

COCO mAP = ortalama AP@[.5:.95]
PASCAL VOC mAP = AP@0.5

YOLOv8n: mAP50-95 = 37.3
YOLOv8x: mAP50-95 = 53.9

Hız & Verimlilik

FPS: Saniyedeki kare sayısı
→ Gerçek zamanlı: >30 FPS

GFLOPs: Giga Floating Ops
Parametre sayısı (Milyon)

Latency (ms): Tek görüntü
Throughput: Batch işleme

YOLOv8 Model Ailesi — Boyut vs mAP vs Hız

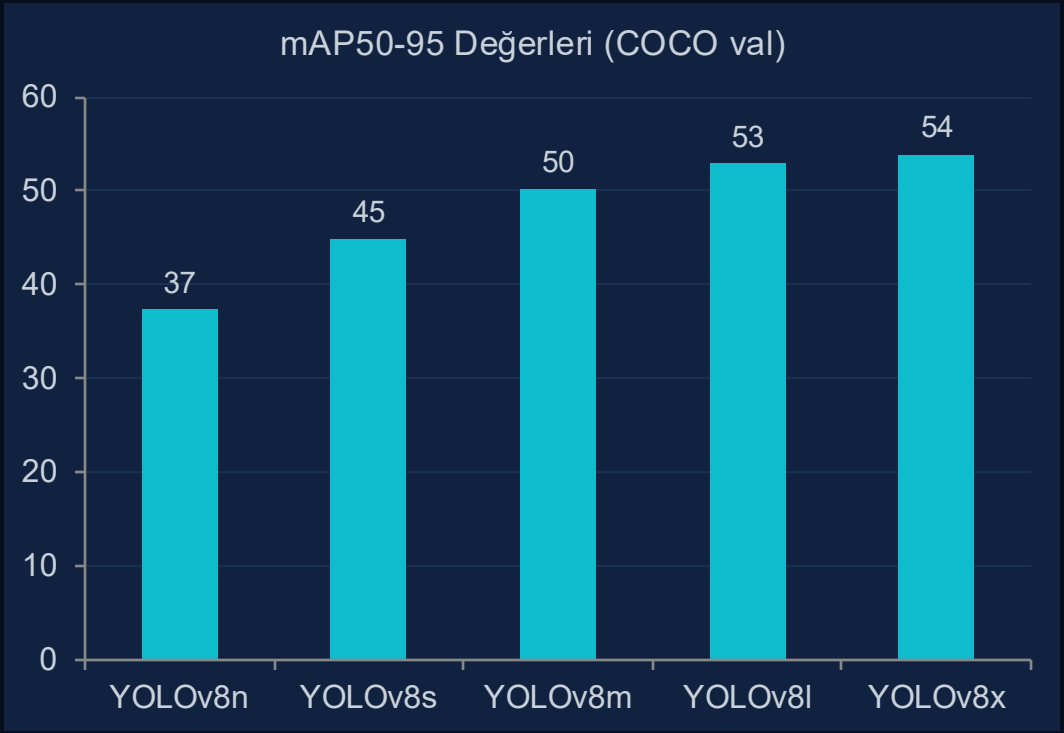

Model	Params	GFLOPs	Hız (ms)
YOLOv8n	3.2M	8.7	1.47
YOLOv8s	11.2M	28.6	2.66
YOLOv8m	25.9M	78.9	5.15
YOLOv8l	43.7M	165	8.06
YOLOv8x	68.2M	258	12.81

n — Nano

Mobil ve edge cihazlar
3.2M parametre

s — Small

Dengeli hız-doğruluk
11.2M parametre

l — Large

Yüksek doğruluk
43.7M parametre

x — XLarge

Maksimum doğruluk
68.2M parametre

Veri Setleri & Etiketleme Araçları

COCO Dataset

330K görüntü, 80 sınıf
1.5M nesne instance

Object Detection
Keypoint Detection
Segmentation & Captioning

mAP@[.50:.95] standart metrik

Pascal VOC

11K görüntü, 20 sınıf

2007 & 2012 versiyonları
XML annotation formatı
mAP@0.5 metriği

Orijinal benchmark dataseti, artık klasik

Open Images v7

9M görüntü, 600 sınıf

Google tarafından
16M bounding box
3M segmentation mask

En büyük annotated open-source dataset

Etiketleme Araçları

- LabelImg — YOLO format
- Roboflow — Cloud platform
- CVAT — Video annotation
- LabelMe — Polygon
- Scale AI — İnsan etiketleme
- Supervisely — Tam pipeline

Gerçek Dünya Uygulamaları

Otonom Araçlar

Yaya & araç tespiti
Şerit & trafik işareti
LiDAR + kamera füzyon
Road segmentation

Şirket: Tesla, Waymo, Mobileye

Tıbbi Görüntüleme

Tümör segmentasyonu
Organ tespiti (BT/MR)
Hücre sayma
Retinal analiz

U-Net & Mask R-CNN
az veriyle yüksek başarı

Endüstriyel Kontrol

Kusur tespiti
Montaj doğrulama
Üretim hattı izleme
Robot yönlendirme

Gerçek zamanlı YOLO
Edge deployment

Güvenlik & Güvenlik

Yüz tespiti & tanıma
Kalabalık analizi
Davranış tespiti
Anomalı aktivite

CCTV + AI entegrasyonu
Gizlilik etik soruları

Tarım & Çevre

Bitki hastalık tespiti
Mahsul sayımı (drone)
Yabani ot tespiti
Orman yangın izleme

Multispectral imagery
Satellite analysis

Perakende & AR

Raf analizi
Ürün tanıma
Arttırılmış gerçeklik
Kasasız mağaza

Amazon Go tarzı
AR try-on uygulamaları

Framework, Araçlar & Dağıtım Ekosistemi

Eğitim Framework'leri

PyTorch — Araştırma standardı
Dynamic graph, autograd

TensorFlow/Keras — Production
TFLite mobile export

Ultralytics YOLO — Kolay API
train, val, predict, export

Veri & Artırma

Albumentations — Hızlı aug.
Flip, crop, blur, CutOut

Roboflow — Veri yönetimi
Annotation, versioning

torchvision — Yerleşik transforms
standart augmentations

Dağıtım & Optimizasyon

ONNX — Çerçeveler arası
platform-bağımsız format

TensorRT — NVIDIA GPU
4-8x hız artışı, FP16/INT8

OpenVINO — Intel CPU/VPU
Edge cihazlar için

Görselleştirme & Takip

WandB — Deney takibi
Metrik, görsel, model log

TensorBoard — Loss/metric
canlı eğitim izleme

Netron — Mimari görsel
ONNX/TF/PyTorch model

Model Seçim Rehberi — Görev × Kısıt Matrisi

Görev	Hız Kritik	Doğruluk Kritik	Edge/Mobil	Az Veri
Nesne Tespiti	YOLOv8n/s	YOLOv8x	YOLOv8n + TFLite	Transfer learning
Semantik Seg.	DeepLabv3 MobileNet	DeepLabv3+ Xception	MobileNetv3-Seg	U-Net pretrained
Instance Seg.	YOLACT	Mask R-CNN X101	YOLOv8-seg nano	Mask R-CNN finetune
Panoptic Seg.	Panoptic-FPN Fast	Mask2Former Swin-L	Sınırlı destek	OneFormer + aug.
Keypoint/Pose	YOLOv8-pose nano	YOLOv8-pose large	YOLOv8-pose n	ViTPose finetune

Transfer learning ve ön eğitimli ağırlıklar (ImageNet/COCO) her zaman ilk tercihiniz olmalıdır.

Özet — Temel Çıkarımlar

01

4 Ana Görev Var

Sınıflandırma → Tespit → Semantik Seg. → Instance Seg. Her biri farklı çıktı ve hesaplama dengesi gerektirir.

02

R-CNN → YOLO Evrimi

İki aşamalı (doğru ama yavaş) → Tek aşamalı (hızlı & dengeli). YOLO bugün de en popüler gerçek zamanlı çözümdür.

03

YOLOv8+ Anchor-Free

v8 ile anchor-free tasarım, decoupled head ve DFL loss birleşimi SOTA'ya ulaşıyor. v10 NMS'yi kaldırdı.

04

Metrik: mAP & IoU

IoU eşiği ve Precision-Recall dengesi projeye göre seçilir. mAP@[.5:.95] COCO standardıdır.

05

Dağıtım: ONNX / TRT

Eğitim PyTorch, dağıtım ONNX/TensorRT/OpenVINO pipeline'ı ile 4-8× hız kazanımı sağlanır.

06

Veri Kalitesi Önce

Hiperparametre optimizasyonundan önce kaliteli annotation ve veri artırma yatırımı yapın.